

大規模言語モデルを用いた複数チャットエージェントによる チャットコミュニティシミュレーション

嶋津 瑛^a 北山 大輔^b

工学院大学情報学部

a) j323402@ns.kogakuin.ac.jp b) kitayama@cc.kogakuin.ac.jp

概要 令和 5 年度版情報通信白書において、2022 年時点での日本における SNS 人口は 1 億人超と見積もられるなど、我が国における SNS の影響力は非常に大きくなっている。また、SNS を利用したマーケティングや、SNS 上の感情や情報の伝播に対する研究などが盛んに行われていることから、SNS 上での交流に対する動向予測システムの必要性が生じる。そこで我々は、大規模言語モデルを用いたエージェントによるチャットコミュニティを作成し、エージェント同士が互いに投稿・返信を行う仮想 SNS 環境を構築することで、SNS 上での様々なコミュニティに対する動向のシミュレーションが行えると考えた。本稿では、Web 上から収集したニュース記事に基づいた検索拡張生成によって投稿を生成するエージェント同士の対話による SNS シミュレーションシステムを提案し、その動作を検証した。検証の結果、提唱手法によって自然な投稿・返信の生成が可能であること、また一定のシミュレーション能力を持つことを確認した。

キーワード 大規模言語モデル、検索拡張生成、マルチエージェントシミュレーション、ソーシャル・ネットワーキング

1 はじめに

ソーシャル・ネットワーキング・サービス (SNS) は、気軽なコミュニケーションの手段として、人々の生活に組み込まれている。我が国ではその傾向が特に顕著であり、令和 5 年度版情報通信白書¹によると、2022 年時点での我が国におけるソーシャルメディア利用者数は 1 億人超と見積もられており、人口の 8 割以上が SNS を利用している計算となる。また、気軽な投稿が可能であるという特徴から、SNS 上の投稿には投稿者の率直な感想が含まれることが多く、鳥海ら [1]・田中ら [2] のように、感情分析の対象として研究対象とされる場合も存在する。

SNS の特徴として、動向の予測困難性がある。SNS では、様々な特性を持ったユーザが流動的に交流を行うため、その動向の予測は極めて困難である。この予測の困難さは、企業によるマーケティング等の効果予測や、研究対象としての分析をも困難にしている。このことから、SNS を利用する人物の特徴やそれらのやり取りなど、より細かい粒度で SNS の動向予測が行える仕組みの必要性が生じる。

そこで我々は、大規模言語モデル (以下、LLM) を用いて動作する複数のチャットエージェントによって、ユーザ間のやり取りをシミュレーションし、交流の模倣・予測を行うシステムを提案する。このシステムでは、LLM を用いて投稿文および返信文を作成するチャットエー




図 1 システムの全体像

ントを複数作成し、それらが相互に投稿や返信を交わし合うことで、人間が SNS 上で行うようなテキストベースでのコミュニケーションのシミュレーションを行う。図 1 に、本研究で提唱するシステムの概要図を示す。

本研究で提唱するシステムでは、図 1 に示す通り、特定のペルソナに従って応答を生成するチャットエージェントが、ある目的やルールを持ったコミュニティに所属する SNS ユーザとして振る舞う。また、エージェントが投稿や返信を生成する際には、Web 上から収集した情報を用い、最新の話題にも対応できるようにする。

このシステムを用いて特定の話題や投稿に関するシミュレーションを行うことによって、その話題や投稿があるコミュニティからどのように解釈されるか予測することができる。

本研究におけるリサーチクエスチョンは次のとおりである。

- LLM が SNS ユーザを模倣することはできるか？
- チャットエージェントによって行われたシミュレ

ションは、実世界の SNS とどれだけ近似しているか？

2 関連研究

2.1 LLMを用いた人間間でのコミュニケーション

およびその関連現象の再現に関する先行研究

Hua らは、LLM に政治体制・戦力・資源などの背景情報を与えた“国家エージェント”同士の会話による外交シミュレーションシステム“WarAgent”を構築している [3]. また、第一次世界大戦等を模した状況での外交関係シミュレーションを行い、適切に背景情報を与えられた LLM が、史実に近い外交関係を構成することを示した.

また大萩は、LLM を用いた複数エージェントによるペア議論システムを作成し、エコーチェンバー現象が各エージェントの意見をどのように変化させるかを調べている [4]. 大萩は、同意見のエージェントとより多く議論するように調整した場合、LLM においてもエコーチェンバー現象が発生することを示した.

他にも、Aher らは、人間を対象とした心理学実験を LLM に行い、人間の結果を再現できるか調査している [5]. Aher らの研究では、最後通牒ゲームやミルグラム実験といった複数の心理学的実験に対し、LLM が人間と同等の回答や実験結果を示すことを報告している.

Hua ら、大萩、Aher らによるこれらの研究は、人間の行うコミュニケーションや、それに付随する諸現象を再現・模倣することのできる能力が、LLM に備わっていることを示唆している.

2.2 LLMを用いた行動シミュレーションに関する先行研究

Park らは、本研究と同様に、LLM を用いたチャットエージェントによる SNS 上での交流シミュレーションを行っている [6]. 本研究は、この Park らの研究をベースとしたものである. 本研究では、Park らの提案手法に加え、最新の話題に関するシミュレーションも可能とするために、検索拡張生成を用いる.

また、Park らは他にも、LLM によって制御される人物エージェントにより、実世界における人間行動のシミュレーションを行っている [7]. Park らの研究は、上記の SNS 交流シミュレーションを現実での行動に拡張したものであった. 本研究とは、シミュレーションの対象が対面での行動である点で異なる.

Chen らも、本研究と同様に、LLM によって制御される複数の人物エージェントを用いた SNS シミュレーションシステム“S³”を実装している [8]. Chen らの研究では、伝達された情報に対するユーザーの反応をモデル化し、情報伝播・感情変化の過程を再現している. 本

研究が交流自体をシミュレーション対象とした点に対し、Chen らは交流内での情報や感情の伝播を対象とした点で異なる.

3 提案手法

本研究では、LLM によって投稿を生成する複数のエージェントによるマルチエージェントシミュレーションによって、SNS 上で行われるユーザ間の関わりを再現するシステムを提案する. このシステムでは、LLM が SNS 上に存在する複数のユーザを演じ、投稿と返信によるテキストベースの交流を行うことで、ユーザ間の交流を模倣する.

この SNS 交流シミュレーションシステムは、図 1 に示す通り、LLM を用いた 2 つのモジュールである“ユーザペルソナ生成 LLM”および“投稿・返信生成 LLM”を中心に構成される. このモジュール構成は Park らによる“Social Simulacra”[6] から継承されたものであるが、本研究では投稿・返信モジュールに対して検索拡張生成 (Retrieval Augmented Generation: RAG)[9] のための情報収集要約機構を付加している.

まず、本システムがシミュレーションを実行する際の流れについて、シミュレーションの各段階と、その概要を表 1 に示す. 各段階の詳細については、以下各節で述べる.

3.1 ユーザペルソナの生成

本研究では、ユーザペルソナを、ユーザの特徴を示す短文と定義する. LLM は、特定の役職や特徴を与えることで、生成される応答の品質や特徴が変化することが知られている [10]. これを利用して、LLM に対し、ユーザペルソナに加えて、そのペルソナに従って応答を生成するように指示するプロンプトを与えることで、特定の特徴を持つユーザをロールプレイさせる.

図 2 にユーザペルソナ生成機構の動作イメージを示す. LLM は、与えられたコミュニティ交流目的に基づいて、ランダムに選ばれた 10 件のユーザペルソナをサンプルとしながらユーザペルソナを生成する. 生成されたユーザペルソナは、サンプル選出の対象となることで、生成結果の多様性を維持する. ユーザペルソナの生成は、ユーザペルソナが設定された必要数に達するまで繰り返して実行される.

ユーザペルソナ生成のため、実際に LLM へ渡されるプロンプトは、表 2 に示すように構成される. 表中の {community_goal} 部分にはコミュニティ交流目的が挿入される. また、<pre>タグで分割されたユーザ情報の個所では、{sample_name} および {sample_persona} にサンプルとして与えられたユーザ名とユーザペルソナが挿入される. 以降示すプロンプトも同様である. なお、

表 1 シミュレーションの段階と概要

段階	概要
ユーザペルソナの生成	与えられたサンプルユーザペルソナを用いた Few-shot プロンプトによって、コミュニティ交流目的から連想される特徴を持ったユーザペルソナを生成する。
投稿生成のための情報収集および要約	ランダムに選ばれたユーザペルソナが、交流目的・ルール・ペルソナに基づき、交流目的の関連情報を Web 検索して、投稿生成へ利用する準備をする。
トップレベル投稿の生成	前段階で選ばれたユーザペルソナが、交流目的・ルール・ペルソナに基づき、前段階で検索した情報を利用し、返信対象となる独立した投稿を生成する。
返信生成のための情報収集および要約	すべてのユーザペルソナが順に、ランダムに選ばれた投稿・返信に対し、投稿・返信の関連情報を Web 検索して、返信生成へ利用する準備をする。
返信の生成	すべてのユーザペルソナが順に、前段階で検索した情報を利用し、トップレベル投稿または返信に対する返信を生成する。




図 2 ユーザペルソナ生成モジュールの動作イメージ

表 2 ユーザペルソナを生成するプロンプト

```

### 指示
入力は、「{community_goal}」を目的としたネット掲示板に参加しているユーザの名前とプロフィールです。
入力を参考にして、同じ形式で新しいユーザ名とプロフィールを作成してください。
ユーザ名は 20 文字以内、プロフィールは 30 文字以内で作成してください。
ユーザ名とプロフィールは、他のユーザと区別できるようにしてください。同じようなユーザ名とプロフィールを作成することは禁止です。
### 入力
%%ここからサンプル数分だけ繰り返し%%
<pre class="user-name" max-length="20">
{sample_name}</pre> :
<pre class="user-description" max-length="30">
{sample_persona}</pre>
%%ここまで繰り返し%%
### 出力
<pre class="name" max-length="20">

```

記号 “%%” で囲まれた文字列はプロンプトに含まれていない。

さらに、ペルソナが生成される際、各ペルソナの情報収集および理解能力を再現するものとして、注目度、注目範囲、理解深度という 3 つのパラメータを与える。注目度および注目範囲には正規分布 $\mathcal{N}(5, 1)$ に従ったランダムな値が、理解深度にはアーラン分布 $Er(3, 1)$ に従ったランダムな値が整数に丸められて与えられる。詳細は 3.3 章に記載した。




図 3 投稿・返信生成モジュールの概要図

3.2 投稿・返信の生成

投稿・返信生成モジュールでは、ユーザペルソナ、コミュニティルール、コミュニティ交流目的から、投稿または返信を生成する。図 3 に、投稿・返信生成モジュールの概要図を示す。

このモジュールでは、LLM にユーザペルソナ、コミュニティルール、コミュニティ交流目的を与えることで、ある交流目的を持つコミュニティに参加しているユーザをロールプレイさせ、SNS の特性である“多様なユーザの存在”を再現する。

LLM の特性として、知識を有していない話題に関しては、不正確な応答である“ハルシネーション(幻覚)”を返すことがある。本システムでは、ハルシネーションを起こしやすいとされる、最新の話題や特定の知識を必要とする話題に対してもシミュレーションを行うために、Web 上の情報を用いた RAG を行うこととする。

このモジュールが生成する投稿は、返信対象を持たない新規投稿である“トップレベル投稿”と、あるトップレベル投稿または返信に対する投稿である“返信”の 2 種類である。また、投稿や返信は、それらの一連のまとまりである“スレッド”単位で管理される。

以下では、トップレベル投稿、返信生成と、そのための情報収集機構について説明する。

表3 検索クエリを生成するプロンプトの共通部分

指示 {user_name}, {user_persona}の立場をロールプレイして, {request}. 検索ワードは, AND 検索の形で, 複数のキーワードを半角スペースで繋いで出力すること. 検索ワードは, セッションごとに改行すること. ### 入力 {input} ### 応答 - サンプル キーワード -

3.3 投稿・返信生成のための情報収集

LLMは, 知識を有していない領域の話題に関して, ハルシネーションを発生させる傾向がある. この特性は, SNSのシミュレーションを目的とする本システムにおいて, シミュレーションの信頼性を損なうことに繋がる. これに対処するため, Web上の記事などを情報源としたRAGを用いることとした.

あるトピックについて調査を行う際, トピックに関する全体的な情報と, そのうち特に興味のある事項に関する詳細な情報を収集する, という検索行動を想定した. これを再現するために, ユーザペルソナが生成されるとき, 興味領域範囲・全体理解範囲・理解深度という3つのパラメータを与え, RAGのための情報の扱いを制御することとした. 以下では, これらをそれぞれ“idea”, “range”, “depth”と呼称する.

RAGのための情報収集・要約は, 次のような段階に沿って行われる.

1. 検索クエリ生成
2. Web上からの記事検索・スクレイピング
3. LexRankによる要約
4. 投稿および返信生成へ利用するための処理

以下では, 各段階について詳細に解説する.

3.3.1 検索クエリ生成

検索クエリ生成部分では, 投稿・返信の作成に必要な情報を検索するためのクエリを, LLMによって生成する. クエリは, コミュニティ交流目的とユーザペルソナに基づいて生成され, SNS上に存在するユーザの検索行動を模倣する. 返信作成の場合は, コミュニティ交流目的とユーザペルソナに加えて, スレッドに存在する既存の投稿・返信も利用して検索クエリを生成する.

検索クエリ生成に用いるプロンプトの共通部分を表3に, 生成対象ごとの差分を表4に示す.

表3に示すプロンプトは投稿および返信生成時の検索クエリ生成に用いるプロンプトである. {request}およ

表4 検索クエリ生成プロンプトの個別部分

対象	{request}	{input}
投稿	“入力されたテーマについて検索する際の検索ワードを出力せよ.”	コミュニティ交流目的
返信	“入力された会話に返信する. その際, 参考として必要な情報を得るためにWeb検索を行う際の検索ワードを出力せよ.”	返信対象スレッドの全投稿

び{input}部には, 表4に示すように, 投稿または返信時によって異なるプロンプトが挿入される.

投稿生成・返信生成のどちらの場合でも, 検索クエリは10個作成される.

3.3.2 Web上からの記事検索・スクレイピング

生成したクエリを使って, 実際にWeb検索を行い, 関連情報が記載された記事を収集する. 前段階で生成された10件の検索クエリのうち, ユーザペルソナに与えられた“idea”値と等しい数だけランダムにクエリを選択し, 検索結果として表示された記事ページの上位10件をスクレイピングする.

Web検索の対象は, 情報源としての信頼性とスクレイピングの容易さを考慮し, NHK NEWS WEB²上のニュース記事を採用することとした. スクレイピングの際は, 記事の題名, 記事内に記載された記事内容の概要, 記事本文を記録する. なお, 動画ニュースなどの非文章コンテンツについては, 検索結果に表示されないよう設定した.

記録した記事の内容は, 後段で要約対象となり, ユーザペルソナに与えられたパラメータの値に従って利用される.

3.3.3 LexRankによる要約

LexRankによる要約段階では, LexRank[11]を用いて推定した, 文ごとの重要度により要約を行う. 各文についてLexRankにより重要度を求めた後, 元の文章の並び順を変えずに, 重要度が上位 $n\%$ までの文を抜き出すことで, 文章長を削減する.

また, 収集した記事全体から得られる情報と, 収集した個別の記事から得られる情報に分けて, 投稿・返信の生成に利用するための処理を行う. 全体情報の要約対象となる記事は“range”値と, 個別情報の要約対象となる記事は“idea”値と同じ数だけ選ばれる. また, これらの情報要約における要約対象および要約後文数は, ユーザペルソナの“depth”値に基づいて, 表5のように決定される. なお, 表中の l は要約前記事における文章長を示し, 個別文章長および全体文章長は要約前記事の文数に対する, 要約後記事の文数の割合を示している.

²<https://www3.nhk.or.jp/news/>

表5 “depth” 値に対する要約後文数

“depth” 値	対象	個別文数		全体文数
		$l < 500$	$l \geq 500$	
0	題名	100%	100%	
1	概要	100%	100%	
2	本文	10%	5%	
3	本文	20%	10%	
4	本文	30%	15%	
5	本文	40%	20%	
6	本文	50%	25%	

表6 トップレベル投稿本文を生成するプロンプト

指示 応答は、ルール「{community_rule}」を守ること。 応答は、{user_persona}の立場をロールプレイして、日本語で行うこと。 応答の文体は、ネット上に投稿される文章として、自然なものにすること。 利用する情報が提示されている場合は、それを利用して応答を生成すること。 ### 利用する情報 {intel} ### 入力 「{community_goal}」を目的とした掲示板に投稿する文章を、{user_persona}の立場から考えてください。 ### 応答 [{user_name}]:

収集・要約した情報は、投稿・返信生成用プロンプト内に含められ、最新の情報を利用した高品質な投稿・返信生成を可能にさせる。

3.4 トップレベル投稿の生成

トップレベル投稿は、議論などの起点になる投稿で、返信対象を持たない独立した投稿である。トップレベル投稿が作成される際には、その投稿を有するスレッドが新規に作成される。ランダムにサンプリングした一定数のペルソナを用いてトップレベル投稿を作成することで、後段の返信生成で返信対象として選択されるスレッドを用意する。

トップレベル投稿の本文の生成には、表6に示すプロンプトを用いた。なお、表中の{community_rule}にはコミュニティルールが、{intel}の部分には収集・要約した記事の内容が挿入される。

3.5 返信の生成

返信は、トップレベル投稿または返信への反応として作成される投稿であり、既存のスレッドに追加される形で投稿される。返信の作成対象となるスレッドはランダムに選択される。

表7に、返信生成に使用されるプロンプトを示す。返信生成に用いるプロンプトの大部分は、表6と同一であるため、各部分での差分のみを記載した。

表7 返信を生成するプロンプト (差分)

指示 入力は、「{community_goal}」を目的とした掲示板のスレッドです。 「{user_persona}」であるユーザ“{user_name}”の立場をロールプレイして、入力されたスレッドに返信する文章を日本語で生成しなさい。 ⋮ ### 入力 {thread} ### 応答 [{user_name}][ReplyTo: {reply_target}]: [
--

表中の{thread_title}には返信対象スレッドのタイトルが挿入される。また、{thread}部分には、返信対象のスレッド内の全投稿が1行ずつ挿入される。応答部では、プロンプトを途中で打ち切り、その先を生成するよう誘導した。

{reply_target}には返信対象の投稿を作成したユーザの名前が挿入される。

4 実験

本研究では、構築したシミュレーション環境によるシミュレーションの性能を評価するために、生成されたペルソナと投稿・返信、スレッドについて評価を行った。なお、各生成に利用したモデルは、パラメータ数700億のrinna-llama-3-youko-70b-instruct-Q4_K_Mである。

以下では、各評価対象に関する評価手法、および本稿で実施する実験についての詳細を示す。

4.1 生成されたペルソナに関する評価手法

ペルソナに関する評価では、コミュニティ交流目的と生成されたペルソナを提示し、次の各項目について、異なる3名の被験者に主観的な評価を行わせた。

1. 提示されたペルソナは文章として破綻していないか
2. 提示されたペルソナはコミュニティ交流目的から連想できる適当なものであるか

4.2 投稿に関する評価手法

投稿評価では、コミュニティ交流目的、コミュニティルール、投稿生成に使用したペルソナ、生成された投稿本文を提示し、以下の項目について、異なる3名の被験者に主観的な評価を行わせた。

1. 投稿内容は文章として破綻していないか
2. 投稿内容がコミュニティ交流目的に適しているか (交流目的から逸脱していないか)
3. 投稿内容はコミュニティルールを守っているか
4. 投稿内容は投稿生成に使用したペルソナから想像されるものになっているか

表 8 ペルソナの文章破綻についての評価結果

シナリオ	一切ない	ほぼない	ややある	多くある
金融政策	181	85	27	7
大谷雑談	159	85	50	6
合計	340	179	77	13

5. 投稿内容はそのコミュニティ交流目的を持つネット掲示板の投稿として自然なものか

評価対象となる投稿は、トップレベル投稿と返信のすべてとした。評価の際は、前後の文脈を無視し、その内容のみについて評価するよう指示した。

4.3 スレッドに関する評価手法

スレッド評価では、コミュニティ交流目的、コミュニティルール、スレッド内のすべての投稿(トップレベル投稿および返信)を提示し、スレッド内で行われているやり取りに対して、次の各項目について異なる3名の被験者に主観的な評価を行わせた。

1. やり取りの内容に破綻がないか
2. やり取りの内容コミュニティ交流目的に適しているか(交流目的から逸脱していないか)
3. やり取りの内容はコミュニティルールを守っているか
4. やり取りはそのコミュニティ目標を持つネット掲示板内でのやり取りとして自然なものか

評価対象となるスレッドは、1つ以上の返信が存在するスレッドとし、トップレベル投稿のみのスレッドは除外した。

4.4 シミュレーションの実行条件

シミュレーションの実行にあたっては、次のようなシミュレーションシナリオを想定した。

- 日銀の金融政策について話し合うこと
交流目的 日銀の金融政策について話し合うこと
ルール 礼儀正しい言葉遣いで議論を行うこと
- 大谷翔平選手の活躍に関する雑談
交流目的 大谷翔平選手の活躍に関する議論
ルール 大谷翔平選手に関連しない話題は避けること

これらのシナリオは、従来手法では有効なシミュレーションが実行できないと考えられる、最新の情報または正確な情報が必要となる話題を想定して設定した。

サンプルのユーザペルソナは、各シナリオに参加しう特性を持ったユーザを想定して各10件設定した。各シナリオについてユーザペルソナ生成・トップレベル投稿および返信生成を行い、シナリオごとに100件の生成されたユーザペルソナと28件のトップレベル投稿およびスレッド、110件の返信について評価を行った。

表 9 ペルソナの適当さについての評価結果

シナリオ	適当	やや適当	やや不適当	不適当
金融政策	166	105	26	3
大谷雑談	196	88	313	33
合計	362	193	39	6

表 10 投稿・返信の文章破綻についての評価結果

シナリオ	一切ない	ほぼない	ややある	多くある
金融政策	186	170	50	8
大谷雑談	199	145	66	4
合計	385	315	116	12

5 実験結果

5.1 生成されたペルソナに関する評価結果

表8にペルソナに文章破綻があるかについての評価結果を、表9にコミュニティ交流目的から連想できるペルソナかについての評価結果を示す。

表8, 表9からは、生成されたペルソナに文章破綻がなく、また交流目的に適したペルソナが生成できたことがわかる。

5.2 投稿に関する評価手法

表10に投稿に文章破綻があるかについての評価結果を、表11に交流目的に関する評価結果を、表12にルールへの適合性に関する評価結果を、表13に投稿のペルソナ適合性についての評価結果を、表14に投稿の自然さについての評価結果を示す。

それぞれの結果を見ると、どの評価項目でも良好な結果を記録していることがわかる。特に、交流目標・ルールに対する投稿の適合性が非常に高く、設定された状況に従った投稿生成を実施できることがわかる。

一方、投稿の文章破綻については、“破綻がややある”または“多くある”が全体の1割強を占めており、一部の投稿文に文章的な整合性の破綻が発生していることがわかる。また、投稿がユーザペルソナに適した内容かについての評価結果も“やや不適当”または“不適当”が全体の2割程度となっており、ユーザペルソナの特徴が投稿内容へ反映されないケースが存在することもわかる。

5.3 スレッドに対する評価結果

表15に投稿に文章破綻があるかについての評価結果を、表16に交流目的に関する評価結果を、表17にルールへの適合性に関する評価結果を、表18に投稿の自然さについての評価結果を示す。

スレッドに関する各項目での評価結果を見ると、スレッドの自然さ以外はシナリオごとの差が小さいことがわかる。これは、シナリオによらず交流目的およびルールに基づいたやり取りを行うことができ、またやり取りの文章の整合性も十分であることを示唆している。

しかしながら、文章破綻については、投稿単体の評価に比して“ほぼない”の比率が大きくなっており、文章

表 11 投稿・返信の交流目標適合性についての評価結果

シナリオ	適合	やや適合	やや不適合	不適合
金融政策	295	94	21	4
大谷雑談	283	96	31	4
合計	578	190	52	8

表 12 投稿・返信のルール適合性についての評価結果

シナリオ	適合	やや適合	やや不適合	不適合
金融政策	330	70	9	5
大谷雑談	270	84	40	20
合計	600	154	49	25

破綻が多くなっていることがわかる。また、自然さについても、同様に投稿単体の評価に比べて“やや不自然”の比率が大きくなっていることから、投稿単体で見れば自然だが、返信ややり取りの一部としては不自然である、という投稿が一定数存在することがわかる。

6 考察

5.1 節で示したユーザペルソナの評価結果では、非常に良好な結果を示しており、与えられたコミュニティ交流目的とサンプルユーザペルソナから、適切なユーザペルソナを生成することができる能力を有していると考えられる。また、ユーザペルソナの文章破綻も一定数存在するという結果が示されているが、これはユーザペルソナの文章長をトークン数で制限していることにより、途中でユーザペルソナが終了してしまうためであると考えられる。この制限はシステムの都合で設定したものであるため、プロンプトの改良やユーザペルソナ生成過程の改良などで改善することができると考えられる。また、先行研究において、ロールプレイのために与える情報量と応答品質の変化量が比例することが示されているため、ユーザペルソナの文章長が長くなれば、生成される投稿もユーザペルソナをより反映したものになる可能性がある。

5.2 節で示した投稿・返信の評価結果では、生成される投稿がコミュニティ交流目的・ルールに従っており、文章破綻も多くないことを示しており、システムおよび LLM が投稿生成能力を十分持っていることが考えられる。“大谷翔平に関する雑談”シナリオのみルール適合性が低くなっているが、近辺の人物に関するゴシップが取り上げられたために、“大谷翔平に関係のない話はしない”というルールが無視されたものだと考えられる。近辺の人物が関係のある話題かどうかについては評価者の主観に依存するため、評価項目としてあまり適切でなかった可能性が考えられる。

また、どちらのシナリオにおいても、ユーザペルソナへの適合性がやや低い結果となった。これは前述の通りユーザペルソナが短文であることに由来する可能性が考えられるが、ほかにも LLM が細かなニュアンスを理解

表 13 投稿のペルソナ適合性についての評価結果

シナリオ	適合	やや適合	やや不適合	不適合
金融政策	202	141	57	14
大谷雑談	192	129	66	27
合計	394	270	123	41

表 14 投稿の自然さについての評価結果

シナリオ	自然	やや自然	やや不自然	不自然
金融政策	228	139	41	6
大谷雑談	219	139	41	15
合計	447	278	82	21

できなかった可能性も考えられる。特に“大谷雑談”シナリオでは、特定の属性を持ったファンというユーザペルソナが非常に多く生成され、その一部には人間が確認してもロールプレイが困難なものもあったため、サンプルユーザペルソナが不適切であった可能性も考えられる。

投稿・返信の自然さに関する評価では、生成された投稿のほぼすべてが自然であるとみなされており、LLM が自然な投稿を生成できることを示唆している。これはシステムの基礎的な能力を示しており、ある投稿や話題に対する反応を予測するという目的に対しては、十分実用可能な性能を有していると考えられる。

5.3 節で示したスレッドに関する評価結果では、投稿に関する評価結果と同じく交流目標・ルールに適したやり取りが可能であることが示唆されている。一方で、スレッドの自然さに関する評価結果は、投稿単体に対する評価よりも低く、やや不自然なやり取りが多いという結果になっている。実際に生成された返信を確認すると、ほとんど同じ内容について再度言及するなど、返答としてはやや不自然な返信も見受けられた。このような返信の生成により、やり取りが不自然なものに感じられることが考えられる。

システムでは、返信の生成時に、スレッド内すべての投稿をプロンプトに含めることとしている。これにより、文章長が長くなりすぎることによってスレッド中の文脈を理解することが困難となり、適切な返答を生成することに失敗する場合があると考えられる。人間が実際に文章ベースのツールでやり取りをする際を考慮して、過去の投稿を一部省略する、内容を要約するなどの処理を追加することで、よりの確な返信生成が可能になることも考えられる。

7 まとめ

我々は、LLM にコミュニティの話題とルールに加えてユーザの特性を与え、大規模なコミュニティにおけるユーザ間でのテキストベース投稿によるやり取りを生成させることで、SNS 上での交流シミュレーションを行うシステムを提唱した。本稿では、複数のシナリオでシミュレーションを実行し、生成されたユーザ特性や投稿

表 15 スレッドの文章破綻についての評価結果

シナリオ	一切ない	ほぼない	ややある	多くある
金融政策	21	41	16	3
大谷雑談	24	39	19	2
合計	45	80	35	5

表 16 スレッドの交流目標適合性についての評価結果

シナリオ	適合	やや適合	やや不適合	不適合
金融政策	56	18	7	0
大谷雑談	52	23	9	0
合計	108	41	16	0

表 17 スレッドのルール適合性についての評価結果

シナリオ	適合	やや適合	やや不適合	不適合
金融政策	55	20	6	0
大谷雑談	55	19	8	2
合計	110	39	14	2

内容、および交流の様子に対する評価を行った。

評価結果は、ユーザ特性および投稿の生成について十分な性能を持っており、交流シミュレーションシステムとして一定の性能を有していることを示した。その一方で、生成された投稿によるやり取りには不自然さが残り、システムの性能には一定の制約があることも明らかとなった。

今後は、ユーザ特性をより細かに表すための拡張や、人間の行動を考慮したスレッド要約機構の追加により、交流シミュレーションシステムとしての性能を向上させる必要があると考えられる。

謝辞

本研究の一部は、2024 年度科研費基盤研究 (C)(課題番号: 24K15197) によるものです。ここに記して謝意を表すものとします。

参考文献

- [1] 鳥海不二夫, 榊剛史, 吉田光男. ソーシャルメディアを用いた新型コロナ禍における感情変化の分析. 人工知能学会論文誌, Vol. 35, No. 4, pp. F-K45.1-7, 2020.
- [2] 田中裕太, 佐野睦夫, 大井翔. SNS における感情分析を用いた関心の変化と要因推定. ヒューマンコンピュータインタラクション研究会報告, Vol. 192, No. 23, pp. 1-6, 2021.
- [3] Wenyue Hua, Lizhou Fan, Lingyao Li, Kai Mei, Jianchao Ji, Yingqiang Ge, Libby Hemphill, and Yongfeng Zhang. War and peace (waragent): Large language model-based multi-agent simulation of world wars, 2024.
- [4] Masaya Ohagi. Polarization of autonomous generative ai agents under echo chambers, 2024.
- [5] Gati V Aher, Rosa I. Arriaga, and Adam Tauman Kalai. Using large language models to simulate multiple humans and replicate human subject studies. In Andreas Krause, Emma Brunskill, Kyunghyun Cho, Barbara Engelhardt, Sivan Sabato, and Jonathan Scarlett, editors, *Proceedings of the 40th International Conference on Machine Learning*, Vol. 202 of

表 18 スレッドの自然さについての評価結果

シナリオ	自然	やや自然	やや不自然	不自然
金融政策	48	18	14	1
大谷雑談	37	29	15	3
合計	85	47	29	4

Proceedings of Machine Learning Research, pp. 337-371. PMLR, 23-29 Jul 2023.

- [6] Joon Sung Park et al. Social simulacra: Creating populated prototypes for social computing systems. In *Proceedings of the 35th Annual ACM Symposium on User Interface Software and Technology*, UIST '22, 2022.
- [7] Joon Sung Park, Joseph O'Brien, Carrie Jun Cai, Meredith Ringel Morris, Percy Liang, and Michael S. Bernstein. Generative agents: Interactive simulacra of human behavior. In *Proceedings of the 36th Annual ACM Symposium on User Interface Software and Technology*, UIST '23, 2023.
- [8] Chen Gao, Xiaochong Lan, Zhihong Lu, Jinzhu Mao, Jinghua Piao, Huandong Wang, Depeng Jin, and Yong Li. S3: Social-network simulation system with large language model-empowered agents, 2023.
- [9] Patrick Lewis, Ethan Perez, Aleksandra Piktus, Fabio Petroni, Vladimir Karpukhin, Naman Goyal, Heinrich Küttler, Mike Lewis, Wentaoh Yih, Tim Rocktäschel, Sebastian Riedel, and Douwe Kiela. Retrieval-augmented generation for knowledge-intensive nlp tasks. In *Proceedings of the 34th International Conference on Neural Information Processing Systems*, NIPS '20, Red Hook, NY, USA, 2020. Curran Associates Inc.
- [10] Benfeng Xu, An Yang, Junyang Lin, Quan Wang, Chang Zhou, Yongdong Zhang, and Zhendong Mao. Expertprompting: Instructing large language models to be distinguished experts, 2023.
- [11] Günes Erkan and Dragomir R. Radev. Lexrank: graph-based lexical centrality as salience in text summarization. *J. Artif. Int. Res.*, Vol. 22, No. 1, p. 457-479, December 2004.